

法律案例类出土简牍数据库平台

需求、功能与技术方案

1 项目概述

本项目拟建设一个面向“法律案例类出土简牍”的学术数据库平台。平台不是普通资料展示页，而是集图文对照、全文检索、标注检索、分类管理、统计绘图、数据上传维护和 AI 辅助分析于一体的研究型数据库系统。

核心目标：把简牍文本、图片、书籍目录、页码、出土地点、时期、文献来源、语法标注和指称标注统一管理，使研究者能够稳定检索、浏览、统计、引用和分析相关材料。

1.1 主要用户

用户类型	主要使用场景
研究人员	检索文本，核对图像，分析语法现象，整理法律案例材料。
项目管理员	上传文字、图片和标注数据，维护目录、分类、元数据和修订记录。
学习者	浏览图文资料，进行基础检索，查看标注和解释。
系统维护者	管理权限、备份、安全、日志和 AI 接口配置。

2 需求归纳

需求类别	说明
图文对照	左侧文字、右侧图片；支持图文并看、仅文字、仅图片；文字可复制；图文可翻页；需要目录功能。
检索与统计	支持关键词全文检索；支持按出土地点单选或多选；支持按句法结构、主语、宾语等标注条件检索；显示命中数量并支持统计绘图。
分类管理	支持按时期、出土地点、文献来源、材料类型、案例类型等维度管理。
重点标注	根据词性、语法现象或指称关系，对文本内容进行标红或高亮。
数据上传	支持正常文字版、语法标注版、指称标注版和图片上传；上传后可随时修改。
大语言模型	调用数据库数据并标明出处；根据指定方法做统计和基础分析；测试 AI 对上古汉语标注和语法识别的能力。

2.1 关键判断

- 本平台的核心难点不是页面，而是数据结构、图文映射和标注体系。
- 句法检索能否实现，取决于标注是否已经细化到词、词性、语法角色和结构关系。
- AI 模块应基于数据库检索结果回答，不能脱离资料直接生成结论。

3 功能设计

3.1 前台功能

模块	功能说明	优先级
图文阅读	按目录、页码、简牍编号进入资料；文字与图片并排显示；支持翻页、复制、缩放和单独查看。	P0
全文检索	输入关键词后检索正文，返回命中条目、上下文、出处和数量。	P0
条件筛选	按出土地点、时期、文献来源、案例类型等条件筛选，支持单选和多选。	P0
标注高亮	对词性、语法角色、指称对象、语法现象进行颜色区分或标红。	P1
统计图表	对检索结果和标注现象进行频次统计，生成柱状图、饼图等图表。	P1
AI 分析	用户提问后，系统检索相关材料，再由模型生成带出处的回答。	P2

3.2 后台功能

模块	功能说明	优先级
资料管理	新增、编辑、删除简牍条目；维护编号、标题、正文、时期、地点和来源。	P0
图片管理	上传、替换、删除图片；维护图片与页码、目录、简牍条目的对应关系。	P0
目录管理	建立书籍、章节、页码、条目的层级结构，支持前台目录跳转。	P0
标注管理	上传和编辑语法标注版、指称标注版，支持标注纠错。	P1
分类管理	维护时期、地点、文献来源、案例类型、标注类型等字典。	P1
权限管理	区分普通用户、编辑者、数据管理员和系统管理员。	P1
AI 配置	配置模型接口、检索范围、提示词模板、出处格式和调用日志。	P2

4 数据与标注方案

4.1 数据层级

建议按以下层级组织资料：

Source 文献来源 / 书籍
-> Catalog 目录章节
-> Page 页面 / 图片
-> Slip 简牍条目
-> Text 正常文本
-> Syntax Annotation 语法标注
-> Reference Annotation 指称标注

该结构可以同时支持目录浏览、图文对照、出处定位、检索统计和 AI 引用。

4.2 主要数据表

数据表	主要字段
Source	source_id、书名、作者、出版信息、说明。
Catalog	catalog_id、source_id、章节名、父级目录、排序号。
PageImage	image_id、source_id、catalog_id、页码、图片地址、排序号。
SlipItem	item_id、编号、标题、正文、时期、出土地点、案例类型、image_id。
Annotation	annotation_id、item_id、标注类型、词、词性、语法角色、指称对象、起止位置。
Category	category_id、分类类型、分类名称、排序号。
AIRecord	record_id、问题、检索材料、回答、出处、模型、时间。

4.3 标注格式

为支持语法检索，建议将标注拆成可查询字段。示例：

字段	示例	用途
word	某甲	原始词或字词单位。
pos	n	词性检索，如名词、动词。
role	subject	语法角色检索，如主语、宾语。
start	0	文本起始位置。
end	2	文本结束位置。


可支持的检索包括：

- 关键词检索、词性检索、语法角色检索、指称检索。
- 简单结构检索，例如 n+v、v+n、subject+predicate。

5 技术方案

5.1 总体架构

建议采用 Frontend + Backend API + Database + Search Engine + Object Storage + AI Service 的分层架构。



5.2 推荐技术栈

层级	推荐方案
前端	Vue 或 React；图表使用 ECharts；图片查看支持缩放、拖拽和翻页。
后端	FastAPI、NestJS、Django 或 Spring Boot；提供 REST API。
数据库	PostgreSQL 或 MySQL；保存文本、目录、元数据、标注和权限数据。
搜索	Elasticsearch、OpenSearch 或数据库全文索引；支持全文检索和组合检索。
对象存储	本地文件服务、MinIO、OSS 或 S3；保存图片 and 导入文件。
AI 接入	大语言模型 API + 检索模块 + 出处控制；后续可接入向量数据库。
部署	Docker 容器化部署，Nginx 反向代理，HTTPS 访问，定期备份。

5.3 检索与统计实现

- 全文检索：初期可用数据库模糊查询或全文索引；数据量增大后接入 Elasticsearch 或 OpenSearch。
- 条件检索：对时期、地点、来源、案例类型等字段建立索引。
- 标注检索：将词性、句法角色、结构模式写入独立标注表，按字段组合查询。
- 统计绘图：后端按条件聚合数据，前端用 ECharts 展示柱状图、饼图和折线图。

5.4 AI 接入实现

AI 模块建议采用 RAG 流程：

用户问题 -> 数据库检索 -> 返回相关文本、标注和出处 -> 大语言模型生成回答 -> 输出答案和引用位置

AI 回答必须附带简牍编号、文献来源、页码或图片编号。若数据库中没有足够依据，系统应提示“未检索到充分材料”，避免生成无法核查的结论。

6 开发阶段建议

6.1 一期：MVP 基础版

1. 图文对照展示：目录、文字、图片、翻页、复制。
2. 后台上传维护：文本、图片、基础元数据可新增、修改、删除。
3. 全文检索：关键词检索、命中数量、出处定位。
4. 条件筛选：按出土地点、时期、文献来源筛选。
5. 基础统计：按地点、时期、来源统计检索结果。

6.2 二期：标注检索与统计

1. 接入语法标注版和指称标注版数据。
2. 支持词性、主语、宾语、指称对象等标注检索。
3. 支持 n+v、v+n 等简单结构检索。
4. 对标注现象进行频次统计和图表展示。

6.3 三期：AI 分析与辅助标注

1. 接入 RAG 问答，回答必须基于数据库资料并返回出处。

- 2. 支持按指定分析方法生成统计解释。
- 3. 开发 AI 辅助标注测试功能，由人工审核后入库。
- 4. 增加调用日志、成本控制和策略。

7 验收标准与风险

7.1 验收标准

模块	验收要点
图文对照	文本与图片对应准确；翻页、目录跳转、复制功能正常。
检索	关键词、地点、时期等条件能正确筛选，并显示命中数量。
标注高亮	指定词性或语法现象能按规则高亮，颜色和文本位置准确。
后台上传	文本、图片、标注数据可上传、修改、删除，前台同步更新。
统计图表	统计结果与检索条件一致，图表显示正常，数据可追溯。
AI 回答	回答基于数据库材料生成，能返回明确出处。

7.2 主要风险

风险	处理建议
图文对应不准	入库前明确书籍、页码、图片、条目之间的映射规则，并提供后台校对功能。
标注粒度不足	先制定标注规范，再开发标注检索；复杂检索放到二期或三期。
古文字检索困难	支持字粒度检索、异体字表和人工同义词表，不完全依赖现代中文分词。
AI 编造内容	采用先检索再回答的机制；无依据时不得生成确定性结论。
维护成本高	后台提供批量上传、批量修改和导入校验，降低人工维护压力。

8 结论

本平台建设应优先解决四件事：数据结构、图文映射、检索统计和后台维护。建议先完成 MVP 基础版，再逐步扩展标注检索、统计绘图和 AI 分析。这样可以降低第一阶段开发风险，也便于后续根据真实材料的标注质量继续升级。